

Aprendizaje automático
Departamento de Ingeniería en Informática
ITBA

Trabajo Práctico 2

Objetivo: Aprender a clasificar datos utilizando clasificadores bayesianos

Aprendizaje bayesiano

1. Una estación de radio tiene dos grupos de oyentes: los "jóvenes" y los "viejos". Los dueños de la estación suponen que el saber si un oyente es *joven* o *viejo* es suficiente para terminar si le va a gustar un programa, independientemente de los gustos o preferencias para cualquier otro programa.

Se sabe que si el oyente es *joven*, hay una probabilidad del 95% de que le guste el programa 1, una probabilidad del 5% de que le guste el programa 2, una probabilidad del 2% de que le guste el programa 3 y una probabilidad del 20% de que le guste el programa 4. Por otra parte, si el oyente es *viejo*, hay una probabilidad del 3% de que le guste el programa 1, una probabilidad del 82% de que le guste el programa 2, una probabilidad del 34% de que le guste el programa 3 y una probabilidad del 92% de que le guste el programa 4. Se sabe además que el 90% de los oyentes son viejos.

Dado este modelo, y el hecho de que a un nuevo oyente le gustan los programas 1 y 3, pero no le gustan los programas 2 y 4, ¿cuál es la probabilidad de que el nuevo oyente sea joven?

2. Consideremos el siguiente vector de atributos binarios:
(scones, cerveza, whiskey, avena, fútbol)

El vector $x = (1,0,1,1,0)$ describiría a una persona a la que a le gustan los scones, pero no la cerveza, bebe whiskey, come avena y no mira partidos de fútbol.

En las siguientes tablas, por columna, se dan los vectores de preferencias de un grupo de 6 ingleses y de 7 escoceses.



Ingleses

0	1	1	1	0	0
0	0	1	1	1	0
1	1	0	0	0	0
1	1	0	0	0	1
1	0	1	0	1	0



Escoceses

1	1	1	1	1	1	1
0	1	1	1	1	0	0
0	0	1	0	0	1	1
1	0	1	1	1	1	0
1	1	0	0	1	0	0

Dado el vector $x = (1,0,1,1,0)$, determinar si esa persona es inglesa o escocesa considerando la hipótesis más probable h_{MAP} .

3. Un supermercado especializado en cereales para el desayuno decide analizar las preferencias de sus clientes. Hacen una pequeña encuesta preguntándoles, a seis clientes elegidos al azar, su edad (mayores o menores de 60 años) y qué cereales prefiere para el desayuno (maíz, granola, azucarados, avena).

Las respuestas de cada cliente se registran en un vector con entradas 1 ó 0 de acuerdo a si le gusta o no cada uno de los cereales. Por ej., el vector (1101) indica que a la persona le gustan todos los cereales excepto los azucarados.

Los clientes mayores de 60 años dan como respuestas (1000), (1001), (1111) y (0001) y los menores de 60 años (0110), (1110).

Un nuevo cliente entra en el supermercado y dice que sólo le gustan la granola y los azucarados. Usando el clasificador naïve de Bayes determinar si esa persona es mayor de 60 años o no.

4. Un psicólogo hace una pequeña encuesta sobre la “felicidad”. Cada participante da como respuestas un vector con entradas 1 ó 0 correspondiendo a las respuestas “sí” o “no” a las preguntas. El vector de preguntas tiene atributos:

$$x = (\text{rico}, \text{casado}, \text{saludable})$$

Por ej., una respuesta (101) indica que la persona es rica, soltera y saludable.

Además, cada participante da como respuesta un valor c tal que

$$c = \begin{cases} 1 & \text{si la persona está contenta con su vida} \\ 0 & \text{sino} \end{cases}$$

Se obtuvieron las siguientes respuestas de las personas “contentas”: (1,1,1), (0,0,1), (1,1,0), (1,0,1) y de las personas “no contentas”: (0,0,0), (1,0,0), (0,0,1), (0,1,0), (0,0,0).

- (a) Calcular la probabilidad de que una persona “pobre”, “casada” y “saludable” esté “contenta”.
- (b) Calcular la probabilidad de que una persona “pobre” y “casada” esté “contenta”.
- (c) Aplicando el clasificador naïve de Bayes, determinar si una persona “pobre”, “casada” y “saludable” estaría “contenta”.
5. En la década de 1920 un grupo de botánicos recolectó datos de 150 lirios. Estas medidas se conocen como los “datos de los lirios de Fisher” y están disponibles en:
- http://www.stat.ncsu.edu/working_groups/sas/sicl/data/irises.dat
- Los datos consisten en 50 muestras de cada una de 3 especies de lirios: setosa, virginica y versicolor.



setosa



versicolor



virginica

Para cada muestra, se tomaron 4 medidas: largo y ancho del sépalos y del pétalo en centímetros.

Como cada observación corresponde a una especie conocida, se pueden comparar los grupos obtenidos con un clasificador con las especies reales.

- (a) Estudiar cómo las medidas de los pétalos y de los sépalos varían entre las especies.

Calcular la media, el desvío estándar, el mínimo, el máximo y el rango de ambas variables para cada especie.

- (b) Estudiar gráficamente si algunas de las medidas servirían para clasificar a las especies.

Graficar, por ej., largo vs. ancho del pétalo para los 150 lirios.

- (c) Suponiendo que las medidas tomadas sobre los lirios siguen una distribución gaussiana:

- i. Aplicar el clasificador naïve de Bayes para determinar la especie de cada lirio en la muestra dada.
- ii. Calcular el porcentaje de datos mal clasificados con el método anterior.
- iii. Encontrar la matriz de confusión.

